Теория вероятностей и математическая статистика

Непараметрические тесты.

Глеб Карпов

ФКН ВШЭ

Непараметрические тесты

Обзор лекции

- **Параметрические** тесты (как в предыдущих лекциях) предполагают конкретную форму распределения данных: нормальность, биномиальность и т.д.
- **Непараметрические** тесты делают меньше предположений о виде распределения. Часто работают с рангами, частотами или знаками отклонений.
- Сегодня рассмотрим классические инструменты:
  1. Критерий согласия Пирсона (goodness of fit)
  2. Тест Шапиро–Уилка (нормальность)
  3. Тест Манна–Уитни (сравнение двух выборок)
  4. Тест Пирсона значимости коэффициента корреляции

Критерий согласия Пирсона

Иначе: goodness-of-fit test

- Предположим, случайная величина X принимает одно из k возможных значений (категорий) $A_1, \dots, A_k$.
- По теории (или по бизнес-модели) мы *заранее* знаем, с какими вероятностями должны встречаться категории:

$$H_0: \; P(X \in A_i) = p_i, \quad i = 1, \dots, k, \qquad \sum_{i=1}^{k} p_i = 1$$

- Наблюдаем выборку размера n и считаем наблюдаемые частоты O_i — сколько раз выпала i-я категория.
- Вопрос: согласуются ли наблюдаемые частоты с заявленным распределением $\{p_i\}$?

Критерий согласия Пирсона

Ожидаемые частоты

- При верности H_0 в i-й категории в среднем должно наблюдаться

$$E_i = n \cdot p_i$$

частот — это **ожидаемые частоты**.

- Идея Пирсона: измерить, насколько велико суммарное расхождение между O_i и E_i по всем категориям.
- Чем больше отклонение $(O_i - E_i)$, тем сильнее данные «противоречат» нулевой гипотезе.
- Статистика согласия:

$$\chi^2_{\text{score}} = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i}$$

Критерий согласия Пирсона

Распределение при нулевой гипотезе

- Если H_0 верна и все E_i достаточно велики (обычно $E_i \geq 5$), то при $n \to \infty$:

$$\chi^2_{\text{score}} \sim \chi^2(k-1)$$

- Число степеней свободы $k-1$: из k категорий одна «связана» условием $\sum O_i = n$.
- Напоминание: $\chi^2(\nu)$ — распределение суммы квадратов ν независимых $\mathcal{N}(0,1)$ случайных величин (см. лекции 16–17).

Критерий согласия Пирсона

Пример 1: постановка задачи

Команда мобильного приложения считает, что пользователи *равномерно* распределяют время между пятью разделами (по 20% на каждый). Нужно проверить, соответствуют ли данные этой модели.

- Понимание реального поведения пользователей важно для приоритизации разработки и рекламных кампаний.
- Данные: $n = 500$ сессий, наблюдаемые частоты по разделам:
  - Раздел 1: $O_1 = 130$
  - Раздел 2: $O_2 = 95$
  - Раздел 3: $O_3 = 88$
  - Раздел 4: $O_4 = 102$
  - Раздел 5: $O_5 = 85$
- Гипотезы:
  - H_0: $p_1 = p_2 = p_3 = p_4 = p_5 = 0.20$ (равномерное распределение)
  - H_1: хотя бы одна из вероятностей отличается от 0.20

Критерий согласия Пирсона

Двусторонний тест

Для тестирования $H_0 : P(X \in A_i) = p_i$ против H_1: $\exists\, i : P(X \in A_i) \neq p_i$:

- Ожидаемые частоты при H_0:
$$E_i = n \cdot p_i, \quad i = 1, \dots, k$$
- Распределение *при нулевой гипотезе*:
$$\chi^2_{\text{score}} = \sum_{i=1}^{k} \frac{(O_i - E_i)^2}{E_i} \sim \chi^2(k-1)$$
- Построение критической области:
$$P_{H_0}\left(\chi^2_{\text{score}} > K\right) = \alpha$$
- Граница критической области: $K = \chi^2_{(k-1,\,\alpha)}$
- Правило принятия решения: Отклонить H_0, если $\chi^2_{\text{score}} > \chi^2_{(k-1,\,\alpha)}$.
- **Интуиция**: большие значения χ^2_{score} означают плохое согласие — отклоняем только *правый* хвост распределения.

Критерий согласия Пирсона

Пример 1: решение

- Гипотезы: $H_0 : p_i = 0.20$ для всех i против H_1: распределение неравномерно (двусторонний тест)
- Данные: $n = 500$, $k = 5$, $\alpha = 0.05$
- Ожидаемые частоты: $E_i = 500 \cdot 0.20 = 100$ для всех i
- χ^2-статистика: $\chi^2_{(4,\,0.05)} = 9.488$

$$\chi^2_{\text{score}} = \frac{(130-100)^2}{100} + \frac{(95-100)^2}{100} + \frac{(88-100)^2}{100} + \frac{(102-100)^2}{100} + \frac{(85-100)^2}{100}$$

$$= \frac{900 + 25 + 144 + 4 + 225}{100} = \frac{1298}{100} \approx 12.98$$

- Решение: $\chi^2_{\text{score}} = 12.98 > \chi^2_{(4,\,0.05)} = 9.488$, поэтому отклоняем H_0.
- Вывод: Имеются достаточно статистически значимые основания для утверждения, что пользователи распределяют время между разделами приложения *неравномерно*. Консервативная гипотеза о равных долях (20%) отклоняется в пользу альтернативной.

Критерий согласия Пирсона

Условия применимости

- Наблюдения должны быть независимыми (каждая сессия — отдельное наблюдение).
- Категории должны покрывать все возможные исходы и не пересекаться.
- Ожидаемые частоты E_i должны быть достаточно велики; эвристика: $E_i \geq 5$ для всех i.
- Если некоторые E_i малы, объединяют соседние категории до выполнения условия.
- Тест проверяет согласие *в целом* — он не указывает, какая именно категория «виновата» в отклонении.

Тест Шапиро–Уилка

Иначе: проверка нормальности выборки

- Многие параметрические тесты (например, t-тест для среднего) предполагают, что данные приходят из нормального распределения.
- **Вопрос**: можно ли считать выборку $\mathcal{X} = \{X_1, \dots, X_n\}$ реализацией нормально распределённой случайной величины?
- Гипотезы:
  - H_0: $X_i \sim \mathcal{N}(\mu, \sigma^2)$ для некоторых μ и σ^2 (данные нормальны)
  - H_1: X_i *не* имеют нормального распределения
- Тест Шапиро–Уилка — один из наиболее мощных классических критериев именно для проверки нормальности на *непрерывных* данных.

Тест Шапиро–Уилка

Идея и статистика W

- Упорядочим выборку: $X_{(1)} \le X_{(2)} \le \ldots \le X_{(n)}$ — **вариационный ряд**.
- При нормальности упорядоченные наблюдения должны быть «похожи» на ожидаемые порядковые статистики нормального распределения.
- Статистика Шапиро–Уилка измеряет согласие вариационного ряда с нормальной моделью:

$$W = \frac{\left(\sum_{i=1}^{n} a_i X_{(i)}\right)^2}{\sum_{i=1}^{n}(X_i - \bar{X})^2}$$

- Коэффициенты a_i зависят только от n и вычисляются по таблицам (из ожидаемых значений порядковых статистик $\mathcal{N}(0,1)$).
- $W \in (0,1]$: значение близкое к 1 — хорошее согласие с нормальностью; малые значения W — признак отклонения от нормальности.

Тест Шапиро–Уилка

Распределение при нулевой гипотезе

- Точное распределение W при H_0 не имеет простой аналитической формы — используют **таблицы критических значений** или p-value из статистического ПО.
- Для фиксированных n и α таблица задаёт критическое значение $W_{(n,\,\alpha)}$:

$$P_{H_0}(W < W_{(n,\,\alpha)}) = \alpha$$

- **Интуиция**: при верной H_0 статистика W обычно *велика*; слишком маленькое W говорит против нормальности.
- Параметры μ и σ^2 *не задаются* — тест проверяет принадлежность к *семейству* нормальных распределений в целом.

Тест Шапиро–Уилка

Пример 2: постановка задачи

Аналитик фондового рынка перед расчётом доверительных интервалов для средней дневной доходности хочет проверить, можно ли считать доходности нормально распределёнными.

- Модели риска (VaR, портфельная оптимизация по Марковицу) часто опираются на нормальность доходностей. Нарушение этого предположения может привести к неверным выводам.
- Данные: $n = 15$ дневных доходностей акции (в %), упорядоченные по возрастанию:

$$-0.8,\ -0.5,\ -0.4,\ -0.3,\ -0.2,\ -0.1,\ 0.2,\ 0.3,\ 0.4,\ 0.6,\ 0.8,\ 0.9,\ 1.1,\ 4.8,\ 5.2$$

- На глаз видны **выбросы** (4.8 и 5.2) — сильное отклонение от симметричного «колокола».
- Гипотезы:
  - H_0: доходности имеют нормальное распределение
  - H_1: доходности не нормальны

Тест Шапиро–Уилка

Левосторонний тест

Для тестирования H_0: данные нормальны против H_1: данные не нормальны:

- Распределение *при нулевой гипотезе*: W принимает значения близкие к 1; критическая область — *левый* хвост.
- Построение критической области:

$$P_{H_0}(W < K) = \alpha$$

- Граница критической области: $K = W_{(n,\,\alpha)}$ — берётся из таблицы Шапиро–Уилка.
- Правило принятия решения: Отклонить H_0, если $W_{\text{score}} < W_{(n,\,\alpha)}$.
- Эквивалентно: отклонить H_0, если p-value $< \alpha$.

Тест Шапиро–Уилка

Пример 2: решение

- Гипотезы: H_0: доходности нормальны против H_1: не нормальны (левосторонний тест по W)
- Данные: $n = 15$, $\alpha = 0.05$
- Критическое значение: $W_{(15,\,0.05)} = 0.877$ (таблица Шапиро–Уилка)
- Статистика W: вычисляется по формуле с коэффициентами a_i (на практике — функция `shapiro.test` в R или `scipy.stats.shapiro` в Python):

$$W_{\text{score}} \approx 0.74$$

- Решение: $W_{\text{score}} = 0.74 < W_{(15,\,0.05)} = 0.877$, поэтому отклоняем H_0.
- Вывод: Имеются достаточно статистически значимые основания для утверждения, что дневные доходности *не* следуют нормальному распределению. Консервативная гипотеза о нормальности отклоняется; для дальнейшего анализа стоит рассмотреть робастные методы или непараметрические альтернативы.

Тест Шапиро–Уилка

Условия применимости

- Наблюдения $X_1, \dots, X_n$ должны быть независимыми и одинаково распределёнными.
- Тест в основном предназначен для **непрерывных** данных.
- Тест чувствителен к **выбросам** и асимметрии — именно поэтому он хорошо «ловит» тяжёлые хвосты, например, в финансовых данных.
- Отклонение H_0 *не говорит*, какое именно распределение верно — только то, что нормальная модель не подходит.

Тест Манна–Уитни

Иначе: ранговый критерий для двух независимых выборок

- Предположим, есть две независимые выборки: $\mathcal{X} = \{X_1, \dots, X_n\}$ и $\mathcal{Y} = \{Y_1, \dots, Y_m\}$.
- **Не требуем** нормальности — в отличие от t-теста Уэлча (лекция 23).
- **Вопрос**: отличаются ли распределения двух групп? Эквивалентно: одна группа систематически даёт большие значения, чем другая?
- Гипотезы (двусторонний тест):
  - H_0: распределения X и Y совпадают (нет сдвига между группами)
  - H_1: распределения X и Y различаются
- Тест Манна–Уилка работает с **рангами**, а не с исходными значениями.

Тест Манна–Уитни

Ранги и статистика U

- Объединяем обе выборки в один набор из $N = n + m$ наблюдений и присваиваем каждому **ранг** от 1 до N (от наименьшего к наибольшему; при совпадениях — средний ранг).
- R_X — сумма рангов наблюдений из выборки $\mathcal{X}$; R_Y — сумма рангов из $\mathcal{Y}$.
- Статистики Манна–Уитни:

$$U_X = R_X - \frac{n(n+1)}{2}, \qquad U_Y = R_Y - \frac{m(m+1)}{2}$$

$$U_{\text{score}} = \min(U_X,\, U_Y)$$

- **Интуиция**: если значения X в среднем больше, чем Y, то ранги у $\mathcal{X}$ будут высокими, U_Y — малым, и U_{score} окажется в левом хвосте.

Тест Манна–Уитни

Распределение при нулевой гипотезе

- При малых n и m используют **таблицы критических значений** $U_{(n,\,m,\,\alpha)}$.
- При больших выборках $(n, m > 20)$ — нормальное приближение:

$$U \sim \mathcal{N}\left(\frac{nm}{2},\ \frac{nm(n+m+1)}{12}\right)$$

$$z_{\text{score}} = \frac{U_{\text{score}} - \dfrac{nm}{2}}{\sqrt{\dfrac{nm(n+m+1)}{12}}}$$

- При верной H_0 обе группы «перемешаны» в ранговом ряду — U_{score} близок к своему математическому ожиданию $nm/2$.
- **Замечание**: тест чувствителен к сдвигу распределений; при различии только формы (масштаба) без сдвига медиан интерпретация сложнее.

Тест Манна–Уитни

Пример 3: постановка задачи

Образовательная платформа сравнивает два формата курса по времени прохождения (в часах). Данные асимметричны и содержат выбросы — t-тест не подходит.

- Сокращение времени обучения напрямую влияет на вовлечённость и завершаемость курсов. Нужно понять, даёт ли новый формат систематически более быстрое прохождение.
- Данные:
  - Формат A (классический): $n = 6$ студентов — 20, 25, 30, 35, 40, 45 часов
  - Формат B (новый): $m = 6$ студентов — 5, 8, 10, 12, 15, 18 часов
- Гипотезы:
  - H_0: времена прохождения в обоих форматах имеют одинаковое распределение
  - H_1: распределения различаются (есть систематическая разница)

Тест Манна–Уитни

Двусторонний тест

Для тестирования H_0: распределения X и Y совпадают против H_1: распределения различаются:

- Шаг 1. Объединить выборки, проранжировать все $N = n + m$ значений.
- Шаг 2. Вычислить R_X, R_Y, затем U_X, U_Y и $U_{\text{score}} = \min(U_X, U_Y)$.
- Построение критической области (малые выборки):

$$P_{H_0}(U_{\text{score}} \leq K) = \alpha$$

- Граница: $K = U_{(n,\, m,\, \alpha/2)}$ — из таблицы (для двустороннего теста).
- Правило принятия решения: Отклонить H_0, если $U_{\text{score}} \leq U_{(n,\, m,\, \alpha/2)}$.
- Для больших выборок: отклонить H_0, если $|z_{\text{score}}| > z_{\alpha/2}$.

Тест Манна–Уитни

Пример 3: решение

- Гипотезы: H_0: распределения совпадают против H_1: распределения различаются (двусторонний тест)
- Данные: $n = m = 6$, $N = 12$, $\alpha = 0.05$
- Ранжирование объединённой выборки:

значение	5	8	10	12	15	18	20	25	30	35	40	45
ранг	1	2	3	4	5	6	7	8	9	10	11	12
группа	B	B	B	B	B	B	A	A	A	A	A	A

- Суммы рангов: $R_X = 7 + 8 + 9 + 10 + 11 + 12 = 57, \quad R_Y = 1 + 2 + 3 + 4 + 5 + 6 = 21$
- Статистики U:

$$U_X = 57 - \frac{6 \cdot 7}{2} = 57 - 21 = 36, \qquad U_Y = 21 - 21 = 0$$

$$U_{\text{score}} = \min(36,\ 0) = 0$$

- Критическое значение: $U_{(6,\,6,\,0.025)} = 5$ (таблица Манна–Уитни, двусторонний тест)
- Решение: $U_{\text{score}} = 0 \le 5$, поэтому отклоняем H_0.
- Вывод: Имеются достаточно статистически значимые основания для утверждения, что время прохождения курса *систематически различается* между форматами A и B. Новый формат B связан с меньшим временем прохождения. Консервативная гипотеза об одинаковых распределениях отклоняется в пользу альтернативной.

Тест Манна–Уитни

Условия применимости

- Выборки X и Y должны быть **независимыми**.
- Наблюдения внутри каждой выборки — независимыми и одинаково распределёнными (i.i.d.).
- Данные как минимум **ординальные** (можно упорядочить); исходная шкала может быть асимметричной или с выбросами.
- Для малых выборок — таблицы; для больших — нормальное приближение.
- Это непараметрическая альтернатива двухвыборочному t-тесту Уэлча, когда нормальность (проверенная, например, тестом Шапиро–Уилка) не выполняется.

Тест значимости корреляции Пирсона

Иначе: t-критерий для коэффициента корреляции

- Не путать с критерием согласия Пирсона (χ^2) из начала лекции: там проверяются частоты категорий, здесь — линейная связь между двумя количественными признаками.
- Имеем парные наблюдения $(X_1, Y_1), \dots, (X_n, Y_n)$ — например, часы подготовки и балл на экзамене у одного и того же студента.
- Напоминание: корреляция показывает силу *линейной* связи:

$$\rho = Corr(X, Y) = \frac{Cov(X, Y)}{\sqrt{Var[X]\,Var[Y]}}$$

- Вопрос: есть ли статистически значимая линейная связь между X и Y, или наблюдаемая корреляция могла возникнуть случайно?
- Гипотезы:
  - $H_0 : \rho = 0$ (линейной связи нет)
  - $H_1 : \rho \neq 0$ (линейная связь есть)

Тест значимости корреляции Пирсона

Выборочный коэффициент корреляции r

- По выборке вычисляют **выборочную корреляцию** r:

$$r = \frac{\sum\limits_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum\limits_{i=1}^{n}(x_i - \bar{x})^2 \sum\limits_{i=1}^{n}(y_i - \bar{y})^2}}$$

- Свойства: $r \in [-1, 1]$; $r \approx 1$ — сильная положительная линейная связь, $r \approx -1$ — сильная отрицательная, $r \approx 0$ — линейной связи не видно.
- r — точечная оценка ρ, но сама по себе не отвечает на вопрос о *значимости*.
- Для проверки $H_0 : \rho = 0$ к выборочному r применяют t-критерий (см. лекцию 19).

Тест значимости корреляции Пирсона

Распределение при нулевой гипотезе

- Если (X, Y) имеют **двумерное нормальное** распределение и $H_0 : \rho = 0$ верна, то:

$$t_{\text{score}} = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t_{(n-2)}$$

- Число степеней свободы $(n-2)$: один параметр «тратится» на $\bar{x}$, другой — на $\bar{y}$.
- **Интуиция**: при $\rho = 0$ коэффициент r колеблется вокруг нуля; большие по модуле r (и, значит, большие $|t_{\text{score}}|$) говорят против H_0.

Тест значимости корреляции Пирсона

Пример 4: постановка задачи

Университет изучает связь между числом часов самостоятельной подготовки в неделю и итоговым баллом на экзамене.

- Понимание этой связи помогает проектировать учебную нагрузку и выявлять студентов, которым нужна дополнительная поддержка.
- Данные: $n = 10$ студентов

часы x_i	1	2	3	4	5	6	7	8	9	10
балл y_i	55	58	52	60	57	63	61	66	64	70

- Гипотезы:
  - $H_0 : \rho = 0$ (нет линейной связи между часами подготовки и баллом)
  - $H_1 : \rho \neq 0$ (линейная связь существует)

Тест значимости корреляции Пирсона

Двусторонний тест

Для тестирования $H_0 : \rho = 0$ против $H_1 : \rho \neq 0$:

- Шаг 1. Вычислить выборочные средние $\bar{x}$, $\bar{y}$ и коэффициент корреляции r.
- Распределение *при нулевой гипотезе*:

$$t_{\text{score}} = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}} \sim t_{(n-2)}$$

- Построение критической области:

$$P_{H_0}\left(|t_{\text{score}}| > K\right) = \alpha$$

- Граница: $K = t_{(n-2,\,\alpha/2)}$
- Правило принятия решения: Отклонить H_0, если $|t_{\text{score}}| > t_{(n-2,\,\alpha/2)}$.

Тест значимости корреляции Пирсона

Пример 4: решение

- Гипотезы: $H_0 : \rho = 0$ против $H_1 : \rho \neq 0$ (двусторонний тест)
- Данные: $n = 10$, $\alpha = 0.05$
- Выборочные средние: $\bar{x} = 5.5$, $\bar{y} = 60.6$
- Выборочная корреляция Пирсона:

$$\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = 128, \quad \sum_{i=1}^{n}(x_i - \bar{x})^2 = 82.5, \quad \sum_{i=1}^{n}(y_i - \bar{y})^2 = 260.4$$

$$r = \frac{128}{\sqrt{82.5 \cdot 260.4}} \approx 0.873$$

- t-статистика: $t_{(8,\,0.025)} = 2.306$

$$t_{\text{score}} = \frac{0.873 \cdot \sqrt{8}}{\sqrt{1 - 0.873^2}} = \frac{0.873 \cdot 2.828}{\sqrt{0.238}} \approx \frac{2.47}{0.488} \approx 5.07$$

- Решение: $|t_{\text{score}}| = 5.07 > t_{(8,\,0.025)} = 2.306$, поэтому отклоняем H_0.
- Вывод: Имеются достаточно статистически значимые основания для утверждения, что между часами подготовки и баллом на экзамене существует *линейная связь* ($r \approx 0.87$). Консервативная гипотеза об отсутствии корреляции отклоняется в пользу альтернативной.

Тест значимости корреляции Пирсона

Условия применимости

- Парные наблюдения (X_i, Y_i) должны быть независимыми (разные студенты — разные пары).
- Тест проверяет именно **линейную** связь: $\rho = 0$ не исключает нелинейной зависимости (например, параболической).
- При больших n тест устойчив к отклонениям от нормальности.
- Для порядковых данных или сильной асимметрии — непараметрический аналог: **ранговая корреляция Спирмена**.

Итоги лекции

- **Пирсон**, критерий согласия (χ^2): согласуются ли наблюдаемые частоты с заданным распределением?
- **Шапиро–Уилк** (W): можно ли считать выборку нормальной?
- **Манна–Уитни** (U): отличаются ли две независимые выборки (без нормальности)?
- **Пирсон**, корреляция (r): есть ли значимая линейная связь между двумя количественными признаками?

Слайд для записи